



BACHARELADO EM SISTEMAS DE INFORMAÇÃO
TRABALHO DE GRADUAÇÃO

JOSÉ CARLOS CECCON NETO

**AVALIAÇÃO DE MODELOS DE DETECÇÃO DE PESSOAS PARA
MONITORAMENTO DE ÁREAS RESTRITAS EM IMAGENS AÉREAS**

Cachoeiro de itapemirim

2026

JOSÉ CARLOS CECCON NETO

**AVALIAÇÃO DE MODELOS DE DETECÇÃO DE PESSOAS PARA
MONITORAMENTO DE ÁREAS RESTRITAS EM IMAGENS AÉREAS**

Trabalho de Conclusão de Curso apresentado à Coordenação do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Orientador: Prof. Dr. Beltrano de Tal

Coorientadora: Profa. Dra. Beltrana de Tal

Cachoeiro de itapemirim

2026

Dados Internacionais de Catalogação-na-Publicação (CIP)
(Biblioteca Nilo Peçanha do Instituto Federal do Espírito Santo)

X999y

Avaliação de Modelos de Detecção de Pessoas para Monitoramento de
Áreas Restritas em Imagens Aéreas / José Carlos Ceccon Neto. – 2026.

46 f: il; 30 cm.

Orientador: Beltrano de Tal

Trabalho de Graduação – Instituto Federal do Espírito Santo, Bacharelado
em Sistemas de Informação, 2026.

1. Sistemas de Informação. 2. Redes de Computadores – Protocolos.
3. Segurança da Informação – Criptografia. 4. Computação em Nuvem
– Serviços. 5. Internet das Coisas (IoT). 6. Engenharia de Software –
Desenvolvimento de Sistemas. I. Borges, Everson Scherrer. II. Instituto
Federal do Espírito Santo. III. Título.

CDD 000.00

JOSÉ CARLOS CECCON NETO

**AVALIAÇÃO DE MODELOS DE DETECÇÃO DE PESSOAS PARA
MONITORAMENTO DE ÁREAS RESTRITAS EM IMAGENS AÉREAS**

Trabalho de Conclusão de Curso apresentado à Coordenadoria do Curso de Sistemas de Informação do Instituto Federal de Educação, Ciência e Tecnologia do Espírito Santo, como requisito parcial para a obtenção do título de Bacharel em Sistemas de Informação.

Aprovado em 01 de Agosto de 2026

COMISSÃO EXAMINADORA

Prof. Dr. Beltrano de Tal

Instituto Federal do Espírito Santo
Orientador

Profa. Dra. Beltrana de Tal

Instituto Federal do Espírito Santo
Coorientadora

Profa. Dra. Fulana de Tal

Instituto Federal do Espírito Santo
Examinadora

Prof. Dr. Cicrano de Tal

Instituto Federal do Espírito Santo
Examinador

A dedicatória é um elemento opcional. Contém o oferecimento do trabalho a determinada pessoa ou a pessoas (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2011b).

AGRADECIMENTOS

A um elemento opcional. Localiza-se após a folha de aprovação e deve ser dirigido àqueles que realmente contribuíram, de maneira relevante, para a elaboração do trabalho. Deve-se utilizar uma linguagem simples (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2011b).

Epigrafe: É um elemento opcional. É uma citação relacionada ao assunto do trabalho desenvolvido, seguida da indicação de autoria (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2011b). Deve-se seguir as regras do uso da citação NBR 10.520/2002.

RESUMO

O monitoramento de áreas restritas por meio de imagens aéreas apresenta desafios importantes para a detecção automática de pessoas, em razão de fatores como reduzida escala dos alvos, variações de perspectiva, condições de iluminação e complexidade do ambiente observado. Nesse contexto, a visão computacional tem se mostrado uma alternativa promissora para apoiar processos de vigilância e identificação de presenças humanas em locais sensíveis. Este trabalho tem como objetivo avaliar modelos de detecção de pessoas aplicados ao monitoramento de áreas restritas em imagens aéreas, buscando identificar quais abordagens apresentam melhor desempenho nesse cenário. Para isso, serão analisados diferentes modelos de detecção de objetos baseados em aprendizado profundo, contemplando abordagens de uma etapa, duas etapas e arquiteturas mais recentes. A metodologia proposta consiste na aplicação e comparação desses modelos em uma base de imagens aéreas, com avaliação realizada por meio de métricas como precisão, recall, F1-score, Intersection over Union, mean Average Precision e tempo de inferência. Espera-se, com este estudo, contribuir para a análise comparativa de modelos de detecção de pessoas em cenários aéreos, fornecendo subsídios técnicos e acadêmicos para futuras aplicações no monitoramento de áreas restritas.

Palavras-chave: Visão Computacional, Detecção de Pessoas, Imagens Aéreas, Monitoramento de Áreas Restritas, Detecção de Objetos

ABSTRACT

Monitoring restricted areas using aerial imagery presents significant challenges for the automatic detection of people due to factors such as small target scale, variations in perspective, lighting conditions, and the complexity of the observed environment. In this context, computer vision has shown promise as an alternative to support surveillance processes and the identification of human presence in sensitive locations. This work aims to evaluate people detection models applied to the monitoring of restricted areas in aerial imagery, seeking to identify which approaches perform best in this scenario. To this end, different object detection models based on deep learning will be analyzed, including one-stage, two-stage, and more recent architectures. The proposed methodology consists of applying and comparing these models to an aerial image database, with evaluation performed using metrics such as precision, recall, F1-score, Intersection over Union, mean Average Precision, and inference time. This study is expected to contribute to the comparative analysis of people detection models in aerial scenarios, providing technical and academic support for future applications in the monitoring of restricted areas.

Keywords: Computer Vision, People Detection, Aerial Imagery, Restricted Area Monitoring, Object Detection

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de predição gerada pelo modelo Faster R-CNN no subconjunto piloto	35
--	----

LISTA DE TABELAS

Tabela 1 – Artefatos produzidos no desenvolvimento inicial	34
Tabela 2 – Resultados preliminares do teste piloto com YOLO11s	36
Tabela 3 – Resultados preliminares dos pilotos com modelos TorchVision . . .	37
Tabela 4 – Tempo de inferência nos pilotos com modelos TorchVision	37
Tabela 5 – Resultados padronizados no subconjunto piloto de teste	38
Tabela 6 – Eficiência computacional padronizada no subconjunto piloto de teste	38

LISTA DE QUADROS

Quadro 1 – Modelos definidos para avaliação experimental	28
Quadro 2 – Ambiente computacional inicialmente identificado	31

LISTA DE SIGLAS

AP	Average Precision
ARP	Aeronave Remotamente Pilotada
CPU	Central Processing Unit
CNN	Convolutional Neural Network
COCO	Common Objects in Context
CUDA	Compute Unified Device Architecture
FPN	Feature Pyramid Network
FPS	Frames per Second
GPU	Graphics Processing Unit
IA	Inteligência Artificial
Ifes	Instituto Federal do Espírito Santo
IoU	Intersection over Union
mAP	mean Average Precision
NMS	Non-Maximum Suppression
RNA	Rede Neural Artificial
RPN	Region Proposal Network
SSD	Single Shot MultiBox Detector
VANT	Veículo Aéreo Não Tripulado
VC	Visão Computacional
VOC	Visual Object Classes
YOLO	You Only Look Once

LISTA DE SÍMBOLOS

λ Letra grega labda

SUMÁRIO

1	INTRODUÇÃO	15
1.1	OBJETIVOS	17
1.1.1	<i>Objetivo Geral</i>	18
1.1.2	<i>Objetivos Específicos</i>	18
2	REFERENCIAL TEÓRICO	19
2.1	VISÃO COMPUTACIONAL E APRENDIZADO PROFUNDO	19
2.2	DETECÇÃO DE OBJETOS	20
2.3	DETECÇÃO DE PESSOAS EM IMAGENS AÉREAS	20
2.4	MODELOS DE DETECÇÃO DE OBJETOS	21
2.4.1	YOLO	21
2.4.2	Faster R-CNN	22
2.4.3	SSD	22
2.5	BASES DE DADOS	23
2.6	MÉTRICAS DE AVALIAÇÃO	23
3	METODOLOGIA	25
3.1	CARACTERIZAÇÃO DA PESQUISA	25
3.2	FLUXO METODOLÓGICO	25
3.3	BASE DE DADOS	26
3.4	PRÉ-PROCESSAMENTO DOS DADOS	27
3.5	MODELOS AVALIADOS	28
3.6	TREINAMENTO E AJUSTE FINO	28
3.7	MÉTRICAS DE AVALIAÇÃO	29
3.8	AMBIENTE COMPUTACIONAL	31
3.9	FORMA DE COMPARAÇÃO DOS RESULTADOS	32
4	RESULTADOS PRELIMINARES	33
4.1	DESENVOLVIMENTO INICIAL DO PROJETO	33
4.2	VALIDAÇÃO DO PIPELINE EXPERIMENTAL	34
4.3	PILOTOS COM YOLO11S	35
4.4	PILOTOS COM FASTER R-CNN E SSD	36
4.5	AVALIAÇÃO PADRONIZADA EM FORMATO COCO	38
4.6	INTERPRETAÇÃO GERAL DOS RESULTADOS PILOTOS	39

4.7	LIMITAÇÕES DOS RESULTADOS PRELIMINARES	40
5	CONCLUSÃO	41
	REFERÊNCIAS	42
	APÊNDICE A – EXPLICAÇÃO	43
	ANEXO A – EXPLICAÇÃO	44
	ANEXO B – EASYREVIEW	45

1 INTRODUÇÃO

Os Veículos Aéreos Não Tripulados (VANTs), também conhecidos como drones ou Aeronaves Remotamente Pilotadas (ARP), têm sido amplamente utilizados em diferentes aplicações civis e institucionais, incluindo monitoramento em tempo real, sensoria-mento remoto, busca e resgate, segurança, vigilância e inspeção de infraestrutura civil (SREENATH *et al.*, 2020; COLOMINA; MOLINA, 2014). Essas plataformas possibilitam a obtenção de imagens aéreas de forma ágil e com ampla cobertura espacial, favore-cendo atividades que demandam observação contínua de grandes áreas ou de regiões de difícil acesso. Além disso, podem operar com câmeras, sensores e dispositivos de geolocalização, contribuindo para a geração de dados atualizados e para a automação de tarefas baseadas em análise visual.

Com o crescimento do uso de drones em diferentes cenários, ampliaram-se também as demandas relacionadas à segurança e ao monitoramento automatizado. Nesse contexto, a análise de imagens aéreas por técnicas de Visão Computacional constitui uma abordagem relevante para apoiar a identificação de pessoas em áreas sensíveis ou de acesso controlado. Segundo Szeliski (2010), a Visão Computacional busca desenvolver métodos capazes de extrair informações semânticas a partir de dados visuais, sendo aplicada em tarefas como detecção, segmentação e reconhecimento de padrões.

Tal aplicação é relevante porque a presença humana em regiões delimitadas pode re-presentar um evento de interesse para fins de vigilância, controle de acesso, prevenção de incidentes ou apoio à tomada de decisão (COLOMINA; MOLINA, 2014). Nesse sentido, a integração entre sistemas embarcados em VANTs e algoritmos inteligentes amplia significativamente a capacidade de monitoramento automatizado (COLOMINA; MOLINA, 2014). Além disso, abordagens baseadas em Redes Neurais Convolucionais, fundamentadas nos avanços do Aprendizado Profundo discutidos por LeCun, Bengio e Hinton (2015) e Goodfellow, Bengio e Courville (2016), têm sido amplamente em-pregadas em tarefas de detecção visual, inclusive em bases e desafios com imagens capturadas por drones (ZHU; WEN; DU, 2018; ZHU *et al.*, 2021).

Entretanto, a detecção de pessoas em imagens aéreas constitui uma tarefa desafiadora.

Em comparação com imagens convencionais, os alvos humanos costumam aparecer em tamanho reduzido, sob diferentes ângulos de visão, com variação de escala, iluminação e complexidade de fundo. Esses desafios estão diretamente relacionados ao problema de detecção de pequenos objetos, discutido em bases aéreas como o VisDrone (ZHU *et al.*, 2021). Também se relacionam às diferenças entre arquiteturas de detecção, como YOLO (REDMON *et al.*, 2016), Faster R-CNN (REN *et al.*, 2015) e SSD (LIU *et al.*, 2016), que adotam estratégias distintas para localização e classificação de objetos.

A literatura da área mostra que métodos clássicos de reconhecimento de padrões vêm sendo progressivamente substituídos por abordagens baseadas em Aprendizado Profundo, especialmente por Redes Neurais Convolucionais, em razão de sua capacidade de extrair automaticamente características relevantes das imagens e alcançar resultados superiores em tarefas de detecção e classificação visual (LECUN; BENGIO; HINTON, 2015; GOODFELLOW; BENGIO; COURVILLE, 2016). Nesse contexto, o desempenho desses modelos depende fortemente da arquitetura utilizada, da qualidade dos dados e das estratégias de treinamento adotadas.

No caso das imagens aéreas, diferentes arquiteturas podem apresentar comportamentos distintos diante das dificuldades impostas por pequenos objetos, variações de perspectiva e cenários visuais complexos. Dessa forma, a escolha de modelos adequados para esse tipo de aplicação torna-se uma questão relevante tanto do ponto de vista técnico quanto acadêmico, especialmente quando se busca equilibrar desempenho de detecção e eficiência computacional. Nesta pesquisa, essa comparação será realizada considerando modelos representativos de diferentes abordagens: YOLO11s, como detector moderno de uma etapa; Faster R-CNN ResNet-50 FPN, como detector de duas etapas; e SSD300 VGG16, como linha de base clássica (Ultralytics, 2026; REN *et al.*, 2015; LIU *et al.*, 2016; PyTorch, 2026).

Diante desse cenário, este trabalho adota como tema a avaliação de modelos de detecção de pessoas para monitoramento de áreas restritas em imagens aéreas. O problema de pesquisa que orienta o estudo pode ser expresso pela seguinte questão: quais modelos de detecção de pessoas apresentam melhor desempenho para o moni-

toramento de áreas restritas em imagens aéreas, considerando métricas de qualidade de detecção e eficiência computacional? Parte-se do pressuposto de que diferentes arquiteturas de detecção apresentam desempenhos distintos nesse cenário, em razão das características específicas das imagens aéreas e das limitações inerentes aos modelos empregados.

A justificativa para a realização desta pesquisa está associada, em primeiro lugar, à sua relevância técnica, uma vez que a comparação entre diferentes modelos de detecção pode auxiliar na identificação de abordagens mais adequadas para aplicações de monitoramento baseadas em imagens aéreas. Além disso, o estudo possui relevância acadêmica, pois contribui para a compreensão do desempenho de modelos de Visão Computacional em um domínio específico, caracterizado por desafios como pequenos objetos, variação de perspectiva, ruído, oclusão e ambientes visualmente complexos. Também se destaca a relevância prática do tema, considerando que sistemas de monitoramento automático podem apoiar futuras aplicações em contextos que demandem controle visual mais eficiente de espaços restritos, como instalações industriais, áreas institucionais e regiões de acesso controlado.

Assim, este trabalho propõe a análise comparativa de modelos de detecção de pessoas em imagens aéreas, buscando identificar suas potencialidades e limitações no contexto de monitoramento de áreas restritas. Para isso, serão consideradas métricas amplamente utilizadas em detecção de objetos, como precisão, recall, F1-score, IoU, mAP e tempo de inferência, permitindo uma análise objetiva do desempenho de cada abordagem (EVERINGHAM *et al.*, 2010; LIN *et al.*, 2014).

1.1 OBJETIVOS

Esta pesquisa tem como propósito central avaliar modelos de detecção de pessoas aplicados ao contexto de imagens aéreas voltadas ao monitoramento de áreas restritas. Para melhor delimitar esse propósito, apresentam-se, a seguir, o objetivo geral e os objetivos específicos do trabalho.

1.1.1 *Objetivo Geral*

Avaliar modelos de detecção de pessoas aplicados ao monitoramento de áreas restritas em imagens aéreas, comparando seu desempenho com base em métricas de qualidade de detecção e eficiência computacional.

1.1.2 *Objetivos Específicos*

- Realizar levantamento bibliográfico sobre Visão Computacional, detecção de objetos, detecção de pessoas e monitoramento por imagens aéreas;
- Selecionar modelos de detecção de pessoas representativos de diferentes abordagens, incluindo YOLO11s, Faster R-CNN ResNet-50 FPN e SSD300 VGG16;
- Definir e organizar uma base de imagens aéreas compatível com o escopo da pesquisa, tendo o VisDrone como base principal;
- Aplicar os modelos selecionados à base de dados escolhida;
- Avaliar o desempenho dos modelos por meio de métricas como precisão, recall, F1-score, Intersection over Union, mean Average Precision e tempo de inferência;
- Comparar os resultados obtidos, identificando vantagens, limitações e adequação de cada modelo ao monitoramento de áreas restritas;
- Identificar o modelo ou abordagem com melhor desempenho para o cenário analisado.

2 REFERENCIAL TEÓRICO

Este capítulo apresenta os principais conceitos que fundamentam a avaliação de modelos de detecção de pessoas em imagens aéreas. São abordados aspectos relacionados à Visão Computacional, ao Aprendizado Profundo, à detecção de objetos, aos desafios associados a imagens capturadas por drones, aos modelos selecionados para comparação, às bases de dados utilizadas e às métricas de avaliação.

2.1 VISÃO COMPUTACIONAL E APRENDIZADO PROFUNDO

A Visão Computacional é uma área da Computação voltada ao desenvolvimento de métodos capazes de interpretar informações visuais a partir de imagens e vídeos. Segundo Szeliski (2010), essa área busca extrair descrições úteis do mundo real a partir de dados visuais, abrangendo tarefas como classificação, detecção, segmentação, reconstrução tridimensional e reconhecimento de padrões.

Nas últimas décadas, o avanço do Aprendizado Profundo modificou significativamente a forma como problemas visuais são tratados. Em vez de depender exclusivamente de descritores manuais, os modelos baseados em redes neurais profundas aprendem representações diretamente a partir dos dados, o que contribuiu para avanços expressivos em tarefas de reconhecimento visual (LECUN; BENGIO; HINTON, 2015; GOODFELLOW; BENGIO; COURVILLE, 2016). Nesse contexto, as Redes Neurais Convolucionais, conhecidas como CNNs, tornaram-se particularmente relevantes para imagens, pois exploram operações de convolução capazes de capturar padrões locais, como bordas, texturas, formas e estruturas mais complexas ao longo das camadas da rede (LECUN; BENGIO; HINTON, 2015).

Em aplicações de monitoramento por imagens aéreas, essas técnicas são especialmente importantes porque permitem a análise automática de grandes volumes de imagens capturadas por drones. Essa automação pode apoiar tarefas de vigilância, inspeção, busca e identificação de eventos de interesse, reduzindo a dependência de análise visual manual em cenários extensos ou de difícil acesso (SREENATH *et al.*, 2020; COLOMINA; MOLINA, 2014).

2.2 DETECÇÃO DE OBJETOS

A detecção de objetos é uma tarefa de Visão Computacional cujo objetivo é localizar e classificar instâncias de objetos presentes em uma imagem. Diferentemente da classificação de imagens, que atribui uma ou mais classes à imagem inteira, a detecção de objetos deve indicar onde cada objeto está localizado, normalmente por meio de caixas delimitadoras, além de atribuir uma classe e uma pontuação de confiança a cada detecção (SZELISKI, 2010).

Em modelos modernos de detecção, a saída geralmente é composta por um conjunto de caixas delimitadoras, classes previstas e probabilidades associadas. Como um mesmo objeto pode gerar múltiplas predições sobrepostas, utiliza-se com frequência uma etapa de pós-processamento denominada *Non-Maximum Suppression* (NMS), responsável por reduzir detecções redundantes e manter as caixas de maior confiança. Esse processo é amplamente empregado em detectores de uma etapa, como YOLO e SSD (REDMON *et al.*, 2016; LIU *et al.*, 2016).

Os modelos de detecção podem ser agrupados, de forma geral, em abordagens de uma etapa e de duas etapas. Detectores de uma etapa realizam diretamente a predição de caixas e classes a partir da imagem de entrada, favorecendo maior velocidade de inferência. Detectores de duas etapas, por sua vez, primeiro geram propostas de regiões candidatas e depois classificam e refinam essas regiões, como ocorre no Faster R-CNN (REN *et al.*, 2015). Essa distinção é relevante para este trabalho porque o monitoramento de áreas restritas exige equilíbrio entre qualidade de detecção e eficiência computacional.

2.3 DETECÇÃO DE PESSOAS EM IMAGENS AÉREAS

A detecção de pessoas em imagens aéreas apresenta desafios específicos em comparação com imagens capturadas em perspectiva terrestre. Em imagens obtidas por drones, pessoas frequentemente aparecem com poucos pixels, em ângulos superiores, parcialmente ocluídas ou misturadas a fundos visualmente complexos. Além disso, alterações de altitude, inclinação da câmera, iluminação, densidade de objetos e movimento da plataforma aérea podem afetar diretamente o desempenho dos modelos

(ZHU; WEN; DU, 2018; ZHU *et al.*, 2021).

Esses fatores aproximam o problema da detecção de pequenos objetos, uma das tarefas mais desafiadoras em detecção visual. Objetos pequenos tendem a apresentar menor quantidade de informação discriminativa, tornando mais difícil separar a classe de interesse do fundo da imagem. Em cenários de monitoramento, esse problema é ainda mais crítico porque a não detecção de uma pessoa em área restrita pode representar uma falha operacional relevante.

No contexto deste trabalho, a detecção de pessoas não será analisada apenas como uma tarefa genérica de reconhecimento visual. A avaliação considera o uso potencial em monitoramento de áreas restritas, o que exige observar não somente a precisão das caixas delimitadoras, mas também a capacidade dos modelos de recuperar o maior número possível de pessoas presentes nas imagens, reduzir falsos positivos e operar em tempo compatível com aplicações práticas.

2.4 MODELOS DE DETECÇÃO DE OBJETOS

Esta pesquisa considera três modelos representativos de diferentes estratégias de detecção: YOLO11s, Faster R-CNN ResNet-50 FPN e SSD300 VGG16. A escolha desses modelos permite comparar uma arquitetura moderna de uma etapa, uma arquitetura clássica de duas etapas e um baseline consolidado de uma etapa.

2.4.1 YOLO

YOLO, acrônimo de *You Only Look Once*, é uma família de modelos de detecção de objetos baseada em predição direta de caixas delimitadoras e classes a partir da imagem de entrada. A proposta original apresentou a detecção como um problema de regressão única, permitindo inferência em tempo real e tornando a arquitetura atrativa para aplicações que exigem baixa latência (REDMON *et al.*, 2016).

Neste trabalho, será utilizado o YOLO11s, disponibilizado pela biblioteca Ultralytics. A escolha da variante “s” está relacionada ao equilíbrio entre desempenho e custo computacional, aspecto relevante para aplicações de monitoramento em que a velocidade

de inferência também deve ser considerada. A documentação da Ultralytics descreve a família YOLO11 como voltada a tarefas como detecção, segmentação e classificação, com suporte a treinamento, validação, predição e exportação de modelos (Ultralytics, 2026).

2.4.2 Faster R-CNN

O Faster R-CNN é um detector de duas etapas que combina uma rede de propostas de regiões, denominada *Region Proposal Network* (RPN), com uma etapa posterior de classificação e refinamento das caixas delimitadoras. Essa arquitetura reduziu a dependência de métodos externos para geração de propostas e tornou o processo de detecção mais integrado e eficiente (REN *et al.*, 2015).

Neste trabalho, o Faster R-CNN ResNet-50 FPN será utilizado como representante de detectores de duas etapas. A presença de uma rede de pirâmide de características, ou FPN, favorece o uso de informações em múltiplas escalas, aspecto relevante para imagens aéreas nas quais pessoas podem aparecer em tamanhos variados. A implementação adotada será a disponibilizada pelo TorchVision, que oferece modelos de detecção pré-treinados e compatíveis com o ecossistema PyTorch (PyTorch, 2026).

2.4.3 SSD

O SSD, ou *Single Shot MultiBox Detector*, é um detector de uma etapa que realiza predições de caixas e classes em múltiplos mapas de características. A arquitetura foi proposta com o objetivo de combinar bom desempenho de detecção com inferência eficiente, eliminando a necessidade de uma etapa separada de propostas de regiões (LIU *et al.*, 2016).

Neste trabalho, será utilizado o SSD300 VGG16 como baseline clássico. Sua inclusão permite comparar os modelos mais recentes com uma arquitetura consolidada na literatura, contribuindo para avaliar se os ganhos obtidos por abordagens modernas são relevantes no cenário específico de imagens aéreas. Assim como o Faster R-CNN, o SSD será implementado por meio do TorchVision (PyTorch, 2026).

2.5 BASES DE DADOS

A escolha da base de dados é uma decisão metodológica central em trabalhos de detecção de objetos, pois o desempenho dos modelos depende diretamente da distribuição das imagens, das classes anotadas, da qualidade das caixas delimitadoras e da proximidade entre os dados de treinamento e o cenário real de aplicação.

O COCO, ou *Common Objects in Context*, é uma base amplamente utilizada em tarefas de detecção, segmentação e reconhecimento visual, contendo objetos em contextos variados e anotações padronizadas (LIN *et al.*, 2014). Embora seja importante para pré-treinamento e comparação geral entre modelos, o COCO não é específico para imagens aéreas capturadas por drones, o que limita sua representatividade para o problema investigado neste trabalho.

Por esse motivo, a base principal da pesquisa será o VisDrone. Esse conjunto de dados foi desenvolvido para desafios envolvendo imagens e vídeos capturados por drones, incluindo tarefas de detecção e rastreamento de objetos. O VisDrone apresenta cenários variados, diferentes condições de iluminação, mudanças de altitude e objetos em pequena escala, características compatíveis com o problema de detecção de pessoas em imagens aéreas (ZHU *et al.*, 2021).

2.6 MÉTRICAS DE AVALIAÇÃO

A avaliação de modelos de detecção de objetos exige métricas capazes de considerar simultaneamente a localização das caixas, a classificação correta dos objetos e a confiança das predições. Entre as métricas mais utilizadas estão precisão, recall, F1-score, IoU, AP, mAP e tempo de inferência.

A precisão representa a proporção de detecções corretas entre todas as detecções produzidas pelo modelo, enquanto o recall representa a proporção de objetos reais que foram corretamente detectados. Em aplicações de monitoramento, o recall possui importância especial porque falsos negativos podem indicar pessoas não detectadas em áreas sensíveis. Por outro lado, a precisão também é relevante, pois falsos positivos podem gerar alertas indevidos e reduzir a confiabilidade do sistema.

A métrica IoU mede o grau de sobreposição entre a caixa delimitadora prevista e a caixa real anotada. Essa medida é utilizada para determinar se uma detecção deve ser considerada correta, a partir de um limiar previamente definido. Já a métrica AP, ou *Average Precision*, resume a relação entre precisão e recall ao longo de diferentes limiares de confiança. O mAP corresponde à média dos valores de AP e é amplamente utilizado em benchmarks de detecção, como PASCAL VOC e COCO (EVERINGHAM *et al.*, 2010; LIN *et al.*, 2014).

No padrão COCO, a avaliação considera múltiplos limiares de IoU, como ocorre no $mAP@0.5:0.95$, além de permitir análises por tamanho de objeto, como AP_{small} , AP_{medium} e AP_{large} (LIN *et al.*, 2014). Essa estratificação é particularmente relevante para esta pesquisa, pois um dos desafios centrais é avaliar a capacidade dos modelos de detectar pessoas pequenas em imagens aéreas.

Além das métricas de qualidade de detecção, esta pesquisa considera o tempo de inferência e a taxa de quadros por segundo, expressa em FPS. Essas métricas permitem avaliar a viabilidade computacional dos modelos, especialmente em aplicações nas quais a resposta precisa ocorrer em tempo próximo ao real.

3 METODOLOGIA

Este capítulo descreve os procedimentos metodológicos adotados para a avaliação comparativa de modelos de detecção de pessoas em imagens aéreas. A metodologia foi estruturada de modo a permitir a comparação entre arquiteturas distintas de detecção de objetos, considerando tanto a qualidade das detecções quanto a eficiência computacional dos modelos no contexto de monitoramento de áreas restritas.

3.1 CARACTERIZAÇÃO DA PESQUISA

Esta pesquisa caracteriza-se como aplicada, experimental e quantitativa. É aplicada porque busca avaliar técnicas de Visão Computacional em um problema prático de monitoramento por imagens aéreas. É experimental porque envolve a execução controlada de modelos de detecção de objetos sobre uma base de imagens previamente definida. É quantitativa porque a comparação entre os modelos será realizada por meio de métricas numéricas de desempenho, como precisão, recall, F1-score, *Intersection over Union* (IoU), *mean Average Precision* (mAP) e tempo de inferência.

O foco da investigação está na detecção de pessoas em imagens capturadas por drones, especialmente em situações nas quais os alvos humanos aparecem em pequena escala, sob diferentes perspectivas e em cenários com variação de iluminação, oclusão e complexidade visual. Dessa forma, a análise não se limita à acurácia geral dos modelos, mas também considera sua adequação ao cenário específico de monitoramento aéreo.

3.2 FLUXO METODOLÓGICO

O fluxo da pesquisa foi organizado em cinco etapas principais: aquisição dos dados, pré-processamento, seleção dos modelos, execução dos testes e análise comparativa dos resultados. Inicialmente, será selecionada uma base de imagens aéreas com anotações de objetos e presença de pessoas. Em seguida, os dados serão preparados para treinamento e avaliação dos modelos, contemplando a padronização das anotações, a verificação das classes de interesse e o redimensionamento das imagens.

Na etapa seguinte, serão definidos e configurados os modelos de detecção avaliados.

Os modelos serão treinados ou ajustados a partir de pesos pré-treinados, utilizando os mesmos conjuntos de dados e critérios de avaliação. Após a execução dos testes, os resultados serão comparados por meio de métricas de desempenho e de eficiência computacional, buscando identificar vantagens, limitações e cenários nos quais cada arquitetura apresenta melhor adequação.

3.3 BASE DE DADOS

A base principal adotada neste trabalho será o VisDrone, um conjunto de dados voltado para tarefas de detecção e rastreamento de objetos em imagens e vídeos capturados por drones (ZHU *et al.*, 2021). A escolha do VisDrone justifica-se pela aderência ao problema de pesquisa, uma vez que suas imagens apresentam variações de altitude, escala, densidade de objetos, iluminação, perspectiva e complexidade de fundo, características comuns em aplicações reais de monitoramento aéreo.

Para este estudo, serão utilizadas as imagens da tarefa de detecção de objetos do VisDrone. As classes *pedestrian* e *people* serão tratadas como uma única classe-alvo, denominada pessoa, pois o objetivo do trabalho é avaliar a capacidade dos modelos de identificar presença humana em áreas monitoradas. As demais classes presentes na base, como veículos e bicicletas, não serão consideradas como alvos principais da avaliação, embora possam aparecer nas imagens como elementos de fundo.

Após a organização local da base, foram identificadas 6.471 imagens no conjunto de treinamento, 548 imagens no conjunto de validação e 1.610 imagens no conjunto de teste. Considerando a união das classes *pedestrian* e *people*, foram contabilizadas 106.396 instâncias de pessoas no treinamento, 13.969 na validação e 27.382 no teste. Esses valores serão utilizados como referência para documentar a cobertura experimental da pesquisa.

Sempre que possível, será mantida a divisão oficial do conjunto de dados em treinamento, validação e teste, evitando repartições aleatórias que possam dificultar a reprodutibilidade e a comparação com outros estudos. Caso seja necessário criar uma divisão própria, a separação será realizada de forma estratificada e documentada, preservando a proporção entre os subconjuntos e registrando a semente aleatória

utilizada.

3.4 PRÉ-PROCESSAMENTO DOS DADOS

O pré-processamento tem como objetivo padronizar os dados de entrada para os diferentes modelos avaliados. Inicialmente, as anotações originais do VisDrone serão verificadas para identificar inconsistências, imagens sem rótulos válidos e ocorrências associadas às classes de interesse. Em seguida, as anotações serão convertidas para os formatos exigidos pelas bibliotecas utilizadas.

Para o modelo YOLO11, as anotações serão convertidas para o formato YOLO, no qual cada objeto é representado pela classe e pelas coordenadas normalizadas da caixa delimitadora. Para os modelos Faster R-CNN e SSD, implementados por meio do TorchVision, as anotações serão organizadas em formato compatível com a estrutura de tensores esperada pelo PyTorch. Além disso, para permitir a comparação uniforme entre os modelos, as anotações reais e as predições serão exportadas para o formato COCO, possibilitando o cálculo padronizado das métricas de detecção (LIN *et al.*, 2014).

As imagens serão redimensionadas de acordo com a configuração de entrada de cada modelo, preservando as caixas delimitadoras correspondentes. No caso do YOLO11, será adotado redimensionamento com preenchimento proporcional, prática comum em modelos da família YOLO. Nos modelos do TorchVision, serão utilizadas as transformações recomendadas para cada arquitetura, mantendo registro da resolução empregada. Como o redimensionamento pode afetar diretamente a detecção de objetos pequenos, essa decisão será considerada na análise dos resultados.

Também poderão ser aplicadas técnicas de aumento de dados, como espelhamento horizontal, variação moderada de brilho e contraste e pequenas alterações de escala. O uso dessas transformações será controlado e documentado, de modo que a comparação entre os modelos permaneça metodologicamente consistente.

3.5 MODELOS AVALIADOS

Foram selecionados três modelos representativos de diferentes abordagens de detecção de objetos: um detector moderno de uma etapa, um detector de duas etapas e um detector clássico utilizado como linha de base. Essa escolha permite comparar arquiteturas com diferentes compromissos entre precisão, recall e velocidade de inferência.

Quadro 1 – Modelos definidos para avaliação experimental

Modelo	Categoria experimental	Implementação
YOLO11s	Detector moderno de uma etapa	Ultralytics (Ultralytics, 2026)
Faster R-CNN ResNet-50 FPN	Detector de duas etapas	TorchVision (REN <i>et al.</i> , 2015; PyTorch, 2026)
SSD300 VGG16	Detector de uma etapa utilizado como baseline clássico	TorchVision (LIU <i>et al.</i> , 2016; PyTorch, 2026)

Fonte: Elaborado pelo autor (2026).

O YOLO11s será utilizado como representante de detectores modernos de uma etapa. Modelos dessa família realizam a predição das caixas delimitadoras e das classes diretamente a partir da imagem de entrada, favorecendo aplicações que demandam velocidade de inferência. O Faster R-CNN será utilizado como representante de modelos de duas etapas, tradicionalmente associados a maior precisão em diversas tarefas de detecção. O SSD300 VGG16 será empregado como baseline clássico, permitindo verificar o ganho obtido por arquiteturas mais recentes em relação a um detector consolidado na literatura.

3.6 TREINAMENTO E AJUSTE FINO

Os modelos serão inicializados com pesos pré-treinados em bases gerais de detecção de objetos, como o COCO, e posteriormente ajustados para o cenário de imagens aéreas. Essa estratégia de transferência de aprendizado é adequada porque reduz o custo de treinamento e permite aproveitar representações visuais previamente aprendidas em grandes bases de imagens.

Para cada modelo, a camada ou cabeça de detecção será adaptada para a classe-alvo pessoa. No YOLO11, a configuração do conjunto de dados indicará apenas a classe de interesse. Nos modelos Faster R-CNN e SSD, as camadas finais de classificação serão ajustadas para considerar a classe pessoa e a classe de fundo.

O treinamento será realizado utilizando o subconjunto de treinamento, enquanto o subconjunto de validação será empregado para acompanhar o desempenho durante o ajuste fino e selecionar o melhor ponto de parada. O subconjunto de teste será reservado exclusivamente para a avaliação final, evitando vazamento de informação entre treinamento e avaliação.

Os principais hiperparâmetros a serem registrados são: número de épocas, tamanho do lote, resolução de entrada, taxa de aprendizado, otimizador, estratégia de aumento de dados, limiar de confiança, limiar de IoU para NMS e semente aleatória. Caso a disponibilidade computacional permita, cada experimento será repetido com diferentes sementes, possibilitando avaliar a estabilidade dos resultados.

Antes da execução dos experimentos completos, foi realizada uma etapa de validação do pipeline experimental. Essa etapa teve como objetivo verificar se a conversão das anotações, a leitura do conjunto de dados, o treinamento, a validação e a geração de métricas ocorrem corretamente. Para isso, foi criado um subconjunto piloto com 300 imagens de treinamento, 100 imagens de validação e 100 imagens de teste, contendo apenas imagens com pelo menos uma instância da classe pessoa. Os testes pilotos contemplaram o YOLO11s, o Faster R-CNN ResNet-50 FPN e o SSD300 VGG16, permitindo validar tanto o fluxo da Ultralytics quanto o fluxo implementado em PyTorch/TorchVision. Os resultados obtidos nessa etapa não serão tratados como resultados finais da pesquisa, mas como evidência de funcionamento do fluxo experimental.

3.7 MÉTRICAS DE AVALIAÇÃO

A avaliação será realizada por meio de métricas amplamente utilizadas em detecção de objetos. A precisão mede a proporção de detecções corretas entre todas as detecções produzidas pelo modelo, enquanto o recall mede a proporção de objetos

reais corretamente detectados. Essas métricas são definidas pelas Equações 3.1 e 3.2.

$$Precisao = \frac{VP}{VP + FP} \quad (3.1)$$

$$Recall = \frac{VP}{VP + FN} \quad (3.2)$$

Nessas equações, VP representa os verdadeiros positivos, FP representa os falsos positivos e FN representa os falsos negativos. O F1-score será utilizado como medida de equilíbrio entre precisão e recall, conforme a Equação 3.3.

$$F1 = 2 \times \frac{Precisao \times Recall}{Precisao + Recall} \quad (3.3)$$

A métrica IoU será utilizada para quantificar a sobreposição entre a caixa delimitadora prevista pelo modelo e a caixa real anotada na base. Uma detecção será considerada correta quando a classe prevista corresponder à classe-alvo e a IoU atingir o limiar definido no protocolo de avaliação.

Também será utilizado o mAP, métrica consolidada para avaliação de detectores de objetos. Serão considerados o mAP@0.5, que utiliza IoU mínima de 0.5, e o mAP@0.5:0.95, que calcula a média em múltiplos limiares de IoU. Para reduzir diferenças entre as ferramentas utilizadas, as predições dos modelos serão registradas em formato COCO e avaliadas por meio de um protocolo comum. Quando disponível, a avaliação também será estratificada por tamanho dos objetos, utilizando métricas como AP_{small} , AP_{medium} e AP_{large} , pois a detecção de pessoas pequenas constitui um dos principais desafios do cenário aéreo.

Além das métricas de qualidade de detecção, será avaliada a eficiência computacional dos modelos. Para isso, serão medidos o tempo médio de inferência por imagem e a taxa de quadros por segundo, expressa em FPS. Essas medidas serão calculadas no

mesmo ambiente computacional para todos os modelos, após um número inicial de inferências de aquecimento, a fim de reduzir interferências de inicialização.

3.8 AMBIENTE COMPUTACIONAL

Os experimentos devem ser executados em um ambiente computacional controlado, com registro das características de hardware e software. Como o tempo de inferência depende diretamente do equipamento utilizado, especialmente da disponibilidade de GPU, a comparação de FPS será considerada válida apenas entre modelos avaliados no mesmo ambiente.

Quadro 2 – Ambiente computacional inicialmente identificado

Item	Configuração
Sistema operacional	Microsoft Windows 11 Pro, 64 bits
Processador	Intel Core i5-12450H, 8 núcleos e 12 processadores lógicos
Memória RAM	Aproximadamente 8 GB
GPU identificada	Intel UHD Graphics; GPU NVIDIA/CUDA não identificada no ambiente local
Python	3.12.10
PyTorch	2.10.0, versão CPU
TorchVision	0.25.0, versão CPU
Ultralytics	8.4.21
pycocotools	2.0.11

Fonte: Elaborado pelo autor (2026).

Caso os experimentos finais sejam executados em outro ambiente, como uma estação com GPU dedicada ou serviço em nuvem, as informações do Quadro 2 deverão ser atualizadas. Essa atualização é necessária porque resultados de tempo de inferência obtidos em CPU não devem ser comparados diretamente com resultados obtidos em GPU.

3.9 FORMA DE COMPARAÇÃO DOS RESULTADOS

A comparação dos modelos será conduzida em três dimensões principais: qualidade de detecção, eficiência computacional e adequação ao cenário de monitoramento aéreo. Na primeira dimensão, serão analisadas as métricas de precisão, recall, F1-score, IoU e mAP. Na segunda, serão avaliados o tempo médio de inferência e o FPS. Na terceira, será discutida a capacidade dos modelos de detectar pessoas pequenas, lidar com cenas densas e reduzir falsos positivos em áreas visualmente complexas.

Para que a comparação seja metodologicamente consistente, todos os modelos deverão ser avaliados no mesmo subconjunto de imagens, com as mesmas anotações de referência e com as predições exportadas em formato COCO. Dessa forma, evita-se comparar métricas geradas por rotinas internas distintas de cada biblioteca, tornando os resultados mais reprodutíveis e mais adequados à análise científica.

Os resultados serão apresentados em tabelas comparativas e gráficos. As tabelas deverão sintetizar as métricas quantitativas de cada modelo, enquanto os gráficos poderão evidenciar diferenças de desempenho, como comparação de mAP, recall e FPS. Também serão incluídos exemplos visuais de detecções corretas, falsos positivos e falsos negativos, permitindo uma análise qualitativa dos erros cometidos pelos modelos.

Por fim, a escolha do modelo mais adequado não será baseada em uma única métrica isolada. O melhor modelo será discutido considerando o equilíbrio entre desempenho de detecção e custo computacional, de acordo com as necessidades do monitoramento de áreas restritas em imagens aéreas.

4 RESULTADOS PRELIMINARES

Este capítulo apresenta os resultados preliminares obtidos na etapa de validação do pipeline experimental. Essa etapa teve como finalidade verificar se o conjunto de dados convertido a partir do VisDrone poderia ser corretamente lido pelos frameworks de treinamento, se as anotações estavam compatíveis com as imagens e se o processo de treinamento, validação e geração de artefatos ocorria adequadamente. Portanto, os resultados apresentados neste capítulo não constituem a comparação final entre os modelos definidos na metodologia, mas uma evidência inicial de funcionamento do fluxo experimental.

4.1 DESENVOLVIMENTO INICIAL DO PROJETO

Como evidência prática do desenvolvimento inicial, foi implementado um pipeline experimental para preparação dos dados, treinamento piloto e avaliação preliminar dos modelos de detecção. Esse pipeline contempla a conversão das anotações do VisDrone para o formato YOLO, a criação de subconjuntos pilotos, a adaptação das anotações para modelos do TorchVision e a execução inicial dos modelos YOLO11s, Faster R-CNN ResNet-50 FPN e SSD300 VGG16.

Os artefatos gerados incluem arquivos de perdas de treinamento, métricas de validação, pesos ajustados dos modelos e imagens com caixas delimitadoras previstas. Dessa forma, o estágio atual do projeto já apresenta um protótipo funcional do fluxo experimental necessário para a comparação dos modelos definidos na metodologia.

A Figura 1 apresenta um exemplo de predição gerada pelo modelo Faster R-CNN no subconjunto piloto. As caixas vermelhas representam as anotações reais da base e as caixas verdes indicam as detecções previstas pelo modelo. A figura evidencia que o pipeline implementado é capaz de gerar saídas visuais interpretáveis, permitindo analisar acertos, perdas de instâncias e possíveis falsos positivos.

Tabela 1 – Artefatos produzidos no desenvolvimento inicial

Artefato	Evidência produzida	Finalidade no projeto
Scripts	Rotinas para inspeção do VisDrone, conversão das anotações, criação de subconjunto piloto, treinamento e avaliação dos modelos.	Automatizar o fluxo experimental e favorecer a reprodutibilidade.
Dataset convertido	Base VisDrone organizada no formato YOLO, com união das classes <i>pedestrian</i> e <i>people</i> na classe pessoa.	Padronizar a entrada dos modelos e viabilizar os testes pilotos.
Métricas	Arquivos com precisão, recall, F1-score, tempo médio de inferência, FPS e perdas de treinamento.	Quantificar o desempenho preliminar dos detectores avaliados.
Checkpoints	Pesos ajustados gerados após os treinamentos pilotos.	Registrar o estado dos modelos treinados e permitir novas inferências.
Imagens de predição	Figuras com anotações reais e caixas previstas pelos modelos.	Apoiar a análise qualitativa das detecções, falsos positivos e falsos negativos.
Predições COCO	Arquivos JSON com as predições dos três modelos no formato COCO.	Permitir avaliação padronizada de precisão, recall, F1-score, mAP e tempo de inferência.

Fonte: Elaborado pelo autor (2026).

4.2 VALIDAÇÃO DO PIPELINE EXPERIMENTAL

Após a conversão das anotações do VisDrone para o formato YOLO, foi criado um subconjunto piloto com 300 imagens de treinamento, 100 imagens de validação e 100 imagens de teste. Nesse subconjunto, foram mantidas apenas imagens contendo pelo menos uma instância da classe pessoa, formada pela união das categorias *pedestrian* e *people* do VisDrone.

A validação preliminar foi realizada em três etapas. Inicialmente, foram executados testes com o modelo YOLO11s, utilizando a biblioteca Ultralytics. Em seguida, foram executados pilotos com os modelos Faster R-CNN ResNet-50 FPN e SSD300 VGG16, utilizando implementações do TorchVision. Por fim, as predições dos três modelos foram exportadas para o formato COCO, permitindo uma avaliação padronizada no mesmo subconjunto de imagens. Todos os modelos foram inicializados com pesos pré-

Tabela 2 – Resultados preliminares do teste piloto com YOLO11s

Configuração	Precisão	Recall	<i>mAP@0.5</i>	<i>mAP@0.5:0.95</i>	Tempo (s)
1 época, 320 px	0,2786	0,0564	0,0412	0,0102	165,117
3 épocas, 640 px	0,3569	0,2576	0,2143	0,0699	878,320

Fonte: Elaborado pelo autor (2026).

das imagens, incompatibilidades no arquivo de configuração do conjunto de dados ou falhas no carregamento das anotações.

Observa-se que o segundo teste, realizado com três épocas e resolução de 640 pixels, apresentou desempenho superior ao primeiro teste em todas as métricas consideradas. O *mAP@0.5* aumentou de 0,0412 para 0,2143, enquanto o recall aumentou de 0,0564 para 0,2576. Esse comportamento sugere que o aumento da resolução de entrada e do número de épocas favoreceu a detecção de pessoas no subconjunto analisado.

4.4 PILOTOS COM FASTER R-CNN E SSD

Após a validação inicial com YOLO11s, foram executados pilotos reais com os modelos Faster R-CNN ResNet-50 FPN e SSD300 VGG16. Esses testes utilizaram o mesmo subconjunto piloto, porém com limite de 50 imagens de treinamento e 20 imagens de validação, uma época de treinamento, tamanho de lote igual a 1 e execução em CPU. O objetivo foi confirmar se os modelos do TorchVision conseguiam ler as anotações convertidas, substituir corretamente as cabeças de detecção para a classe pessoa e gerar perdas, métricas e imagens de predição.

Nos modelos do TorchVision, a classe pessoa foi mapeada para o índice 1, pois o índice 0 é reservado para a classe de fundo. A avaliação preliminar utilizou limiar de confiança igual a 0,25 e considerou como verdadeiro positivo uma detecção cuja interseção sobre união com uma anotação real fosse maior ou igual a 0,50. A Tabela 3 apresenta os resultados obtidos.

A Tabela 4 apresenta o tempo médio de inferência por imagem e a taxa de quadros por segundo obtidos nos pilotos. Esses valores devem ser interpretados com cautela, pois

Tabela 3 – Resultados preliminares dos pilotos com modelos TorchVision

Modelo	Precisão	Recall	F1	VP	FP	FN
Faster R-CNN ResNet-50 FPN	0,4495	0,2817	0,3463	129	158	329
SSD300 VGG16	0,0003	0,0022	0,0004	1	3999	457

Fonte: Elaborado pelo autor (2026).

foram medidos em CPU e com subconjunto reduzido de validação.

Tabela 4 – Tempo de inferência nos pilotos com modelos TorchVision

Modelo	Tempo médio por imagem (s)	FPS
Faster R-CNN ResNet-50 FPN	2,4302	0,4115
SSD300 VGG16	0,2931	3,4119

Fonte: Elaborado pelo autor (2026).

O Faster R-CNN apresentou desempenho inicial superior ao SSD em precisão, recall e F1-score, embora tenha sido consideravelmente mais lento em CPU. Esse comportamento é coerente com a característica de modelos de duas etapas, que tendem a realizar processamento mais custoso por imagem em razão da geração e refinamento de propostas de regiões (REN *et al.*, 2015).

O SSD apresentou comportamento inadequado neste piloto, com número muito elevado de falsos positivos. A inspeção qualitativa das imagens de predição indicou a geração de muitas caixas em regiões de borda e em áreas sem presença humana. Esse resultado não permite concluir que o SSD seja inadequado ao problema, mas indica que o modelo exige revisão de configuração, ajuste do limiar de confiança, treinamento por mais épocas e avaliação com protocolo mais robusto antes de qualquer comparação final.

As métricas apresentadas nesta seção foram utilizadas principalmente para verificar se os modelos do TorchVision estavam treinando, inferindo e gerando artefatos corretamente. A comparação mais adequada entre os três detectores é apresentada na seção seguinte, na qual todos os modelos são avaliados por um mesmo protocolo em formato COCO.

4.5 AVALIAÇÃO PADRONIZADA EM FORMATO COCO

Após a execução dos pilotos, foi realizada uma avaliação padronizada para reduzir a diferença entre as métricas geradas nativamente pelo YOLO11s e as métricas inicialmente calculadas para os modelos do TorchVision. Para isso, as anotações reais e as predições dos três modelos foram convertidas para o formato COCO, permitindo calcular as mesmas métricas para YOLO11s, Faster R-CNN ResNet-50 FPN e SSD300 VGG16.

A avaliação padronizada foi conduzida no subconjunto piloto de teste, composto por 100 imagens e 2.189 instâncias anotadas da classe pessoa. Para as métricas precisão, recall e F1-score, foi adotado limiar de confiança igual a 0,25 e limiar de IoU igual a 0,50. Para o cálculo de *mAP*, foi utilizado o protocolo COCO, contemplando *mAP@0.5* e *mAP@0.5:0.95*. A Tabela 5 apresenta os resultados de qualidade de detecção.

Tabela 5 – Resultados padronizados no subconjunto piloto de teste

Modelo	Precisão	Recall	F1	<i>mAP@0.5</i>	<i>mAP@0.5:0.95</i>
YOLO11s	0,7950	0,0585	0,1089	0,1301	0,0478
Faster R-CNN ResNet-50 FPN	0,2118	0,1617	0,1834	0,0895	0,0339
SSD300 VGG16	0,0002	0,0027	0,0004	0,0000	0,0000

Fonte: Elaborado pelo autor (2026).

A Tabela 6 apresenta as métricas de eficiência computacional obtidas no mesmo subconjunto de teste. Esses valores foram medidos em CPU e, portanto, devem ser interpretados como evidência preliminar de custo computacional, não como desempenho final em ambiente de produção.

Tabela 6 – Eficiência computacional padronizada no subconjunto piloto de teste

Modelo	Tempo médio por imagem (s)	FPS
YOLO11s	0,1103	9,0668
Faster R-CNN ResNet-50 FPN	2,2035	0,4538
SSD300 VGG16	0,5345	1,8709

Fonte: Elaborado pelo autor (2026).

Os resultados padronizados indicam que o YOLO11s apresentou a maior precisão, o maior $mAP@0.5$, o maior $mAP@0.5:0.95$ e a maior taxa de quadros por segundo no subconjunto piloto de teste. O Faster R-CNN, por outro lado, apresentou maior recall e maior F1-score, o que sugere maior capacidade inicial de recuperar instâncias da classe pessoa nesse subconjunto, embora com custo computacional significativamente superior. O SSD300 VGG16 apresentou desempenho muito baixo, mantendo comportamento instável e grande quantidade de falsos positivos.

Mesmo com a padronização, esses resultados ainda não devem ser interpretados como conclusão final do trabalho. Eles demonstram que o protocolo comparativo foi implementado e que as métricas podem ser calculadas de forma uniforme entre os modelos, mas os treinamentos utilizados ainda são pilotos, com poucas épocas e subconjuntos reduzidos.

4.6 INTERPRETAÇÃO GERAL DOS RESULTADOS PILOTOS

De forma geral, os testes preliminares indicam que o pipeline experimental está funcional para as três arquiteturas previstas na metodologia: YOLO11s, Faster R-CNN ResNet-50 FPN e SSD300 VGG16. Foram gerados pesos ajustados, arquivos de perdas, métricas quantitativas e imagens de predição para inspeção visual. Essa validação é importante porque reduz o risco de problemas estruturais na etapa posterior de experimentos completos.

Apesar disso, os valores obtidos ainda são baixos para uma aplicação final de monitoramento de áreas restritas. Isso é esperado, pois os testes foram conduzidos com subconjuntos reduzidos, poucas épocas de treinamento e execução em CPU. Além disso, o problema analisado envolve pessoas pequenas em imagens aéreas, condição reconhecidamente desafiadora para modelos de detecção de objetos (ZHU *et al.*, 2021).

Do ponto de vista qualitativo, as imagens de validação geradas indicaram que o YOLO11s e o Faster R-CNN foram capazes de produzir algumas detecções coerentes de pessoas em cenas aéreas. Entretanto, também foram observadas perdas de instâncias, especialmente em regiões com objetos pequenos, alta densidade de pessoas ou presença de fundo visualmente complexo. No caso do SSD, a quantidade de falsos

positivos no piloto reforça a necessidade de análise específica dos limiares de confiança e do comportamento das predições.

4.7 LIMITAÇÕES DOS RESULTADOS PRELIMINARES

Os resultados apresentados não devem ser interpretados como evidência conclusiva sobre o desempenho dos modelos nem como resposta definitiva ao problema de pesquisa. O objetivo desta etapa foi exclusivamente validar a execução do pipeline experimental. Entre as principais limitações desta validação preliminar, destacam-se:

- uso de subconjuntos reduzidos do VisDrone;
- treinamento com poucas épocas;
- execução em CPU, o que limita a análise de tempo de inferência;
- avaliação padronizada ainda restrita ao subconjunto piloto, não à base completa;
- ausência de avaliação final com modelos treinados em configuração robusta;
- ausência de discussão sistemática por tamanho dos objetos;
- ausência de análise sistemática de falsos positivos e falsos negativos em todo o conjunto de teste;
- uso de limiar de confiança preliminar, especialmente crítico para o SSD.

Dessa forma, a próxima etapa da pesquisa consistirá na execução dos experimentos completos com os três modelos definidos, utilizando o mesmo protocolo de avaliação, preferencialmente em GPU. Esses experimentos deverão empregar métricas padronizadas, como precisão, recall, F1-score, $mAP@0.5$, $mAP@0.5:0.95$, tempo médio de inferência e FPS, permitindo comparar desempenho de detecção e eficiência computacional de forma consistente.

5 CONCLUSÃO

É a constatação da pesquisa, elucidando se foi ou não alcançado o objetivo proposto. Sugere-se que sejam feitas recomendações finais para implementação do assunto enfocado e, também, a realização de pesquisas adicionais.

REFERÊNCIAS

- COLOMINA, I.; MOLINA, P. Unmanned aerial systems for photogrammetry and remote sensing. **ISPRS Journal**, 2014.
- EVERINGHAM, M. *et al.* The pascal visual object classes (voc) challenge. **International Journal of Computer Vision**, v. 88, n. 2, p. 303–338, 2010.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015.
- LIN, T.-Y. *et al.* Microsoft coco: Common objects in context. In: **European Conference on Computer Vision**. [S.l.]: Springer, 2014. p. 740–755.
- LIU, W. *et al.* Ssd: Single shot multibox detector. In: **European Conference on Computer Vision**. [S.l.]: Springer, 2016. p. 21–37.
- PyTorch. **Models and Pre-trained Weights**. 2026. Disponível em: <<https://docs.pytorch.org/vision/master/models.html>>. Acesso em: 01 jun. 2026.
- REDMON, J. *et al.* You only look once: Unified, real-time object detection. In: **CVPR**. [S.l.: s.n.], 2016.
- REN, S. *et al.* Faster r-cnn: Towards real-time object detection with region proposal networks. In: **NIPS**. [S.l.: s.n.], 2015.
- SREENATH, S. *et al.* Assessment and use of unmanned aerial vehicle for civil structural health monitoring. **Procedia Computer Science**, v. 170, p. 656–663, 2020. ISSN 1877-0509. The 11th International Conference on Ambient Systems, Networks and Technologies (ANT) / The 3rd International Conference on Emerging Data and Industry 4.0 (EDI40) / Affiliated Workshops. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S1877050920306384>>.
- SZELISKI, R. **Computer Vision: Algorithms and Applications**. [S.l.]: Springer, 2010.
- Ultralytics. **YOLO11**. 2026. Disponível em: <<https://docs.ultralytics.com/models/yolo11/>>. Acesso em: 01 jun. 2026.
- ZHU, P. *et al.* Detection and tracking meet drones challenge. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 44, n. 11, p. 7380–7399, 2021.
- ZHU, P.; WEN, L.; DU, D. Vision meets drones: A challenge. **arXiv preprint arXiv:1804.07437**, 2018.

APÊNDICE A – EXPLICAÇÃO

É um elemento opcional. É um documento elaborado pelo próprio autor com o objetivo de completar sua argumentação, sem que haja prejuízo para a unidade do trabalho (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2011b. Deve ser precedido da palavra APÊNDICE (ex:APÊNDICE A, APÊNDICE B), identificado por letras maiúsculas consecutivas, travessão e pelo respectivo título.

ANEXO A – EXPLICAÇÃO

É um elemento opcional. Não é elaborado pelo próprio autor mas sim por outras pessoas e constitui-se de suportes elucidativos e ilustrativos importantes para a compreensão do texto (ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS, 2011b). Havendo mais de um anexo, sua identificação deve ser feita por letra maiúscula ou algarismo arábico (ex:ANEXO A, ANEXO B), identificado por letras maiúsculas consecutivas, travessão e pelo respectivo título.

ANEXO B – EASYREVIEW

THE ALERT COMMAND

Command intended to claim author's attention to a given part of the text. In the following, it is possible to see an example:

- 1 A text without the alert command. \alert{A text with the alert command}.

A text without the alert command. A text
with the alert command.

THE HIGHLIGHT COMMAND

Command intended to claim author's attention to a given part of the text in a different to the "alert" command. In the following, it is possible to see an example:

- 1 A text without the highlight command. \highlight{A text with the highlight command}.

A text without the highlight command. A
text with the highlight command.

THE REMOVE COMMAND

Command which an author suggest to remove a given part of the text. In the following, it is possible to see an example:

- 1 This text is not to be removed. \remove{This text is to be removed}.

This text is not to be removed. This text
is to be removed.

THE ADD COMMAND

Command which an author suggest to add new text in a given part of the text. In the following, it is possible to see an example:

1 This text was already in the text. `\add`{This text is been added now}.

This text was already in the text. This
text is been added now.

THE REPLACE/SUBSTITUTE COMMAND

Both commands are equivalent. It shall be used when an author suggest to replace a given part of the text for a newer one. In the following, it is possible to see an example:

1 `\replace`{This part of the text needs to be replaced}{for this newer part of the text }.

~~This part of the text needs to be replaced~~
for this newer part of the text.

THE COMMENTREVIEW COMMAND

Command intended to claim author's attention to a given part of the text, giving some comments to provide more information. In the following, it is possible to see an example:

1 `\commentreview`{This text will receive a comment.}{This is the comment I have!}.

This text will receive a comment.

This is the comment I have!